Марко Гордић ИН 37/2023

Јована Минчић ИН 4/2023

Предикција тежине исхода саобраћајне незгоде коришћењем кластеризације и фази логике

(Саобраћајне незгоде)

Извештај

1. Увод

1.1. Предмет

Предмет рада је анализа скупа података о саобраћајним незгодама у Републици Србији у 2025. години, обогаћеног метеоролошким подацима и подацима о путевима с циљем предвиђања тежине исхода незгоде (материјална штета, повређени, погинули) применом два различита приступа и њиховог међусобног поређења.

1.2. Циљ

Желимо да применом технике кластеризације пронађемо обрасце у подацима на основу којих ћемо поузданије моћи да вршимо предикцију тежине исхода несреће, с друге стране радимо и обраду природног језика и примену фази система с истим циљем што боље предикције. Пошто предикције вршимо на основу различитих параметара и коришћењем различитих приступа, крајњи циљ нам је да упоређивањем њихових резултата, дођемо до закључка који приступ даје боље предикције, односно шта је круцијални фактор за предвиђање тежине исхода несреће и који су главни разлози таквих исхода.

1.3. Задаци

Наше истраживање обухвата слеће задатке:

- Обогаћивање почетног скупа података - проширивање скупа метеоролошким подацима путем Open-Meteo API-ја и подацима о путевима из OpenStreetMap базе

- Припрема података - чишћење, трансформација и нормализација обележја, идентификација и обрада недостајућих вредности, као и екстракција временских обележја (сат, месец, дан у недељи)

- Истражна анализа - анализа расподеле обележја, расподела циљне променљиве (тежина исхода), временска и просторна анализа, корелациона анализа и идентификација образаца у подацима

- Кластеризација - примена K-means алгоритма над просторним, временским и метеоролошким обележјима ради откривања скривених образаца у подацима уз одређивање оптималног броја кластера методама „лакта" и „силуете"

- Имплементација вишеслојне неуронске мреже - развој предиктивног модела који, на основу метеоролошких (температура, ветар, облачност, WMO код), временских (сат, месец), просторних (географска ширина и дужина), и категоријалних обележја (категорија незгоде) укључујући и добијене кластере као додатно улазно обележје, са циљем боље предикције

- Обрада природног језика - анализа текстуалних описа незгода и издвајање значајних обележја (број и врста учесника, тип судара, маневр, контекст)

- Статистичка анализа - примена Crosstab анализе, Chi-square теста независности и Крамеровог коефицијента V ради утврђивања јачине везе између издвојених обележја и тежине исхода незгоде

- Имплементација Мамданијевог фази система - дефинисање фази правила на основу резултата статистичке анализе и класификација тежине исхода

- Евалуација модела - примена метрика класификације (F1 (macro) мера као референтна метрика, тачност, прецизност, одзив, матрица конфузије) за оба развијена модела

- Анализа резултата - упоређивање перформанси оба приступа као и идентификација кључних фактора који доприносе тежини исхода незгоде и извођење закључака на основу свега тога

1.4. Очекивани резултати

Очекује се да примењене методе омогуће што поузданију предикцију типа саобраћајне несреће, као и откривање значајних образаца у подацима који нису директно видљиви у изворном скупу. Кластеризација треба да идентификује групе незгода са сличним просторним, временским и метеоролошким карактеристикама, чиме се неуронској мрежи пружа додатни контекст за класификацију и тиме омогућава што боља предикција. Истовремено, очекује се да обрада природног језика над текстуалним описима незгода омогући издвајање обележја која у подацима нису директно доступна - попут типа учесника, врсте судара и контекста у којем се незгода десила, док ће статистичка анализа утврдити која су од њих најјаче повезана са тежином исхода, чиме ће се формирати основа за фази правила Мамданијевог система. Упоређивањем ових приступа ће се утврдити њихова ефикасност и допринос разумевању фактора који доводе до одређених исхода.

2. Методологија

2.1. Коришћени подаци

Коришћени скуп података садржи информације о саобраћајним незгодама и представља структурисане табеларне податке. Подаци обухватају атрибуте као што су јединствени број незгоде, полицијска управа, општина, датум и време саобраћајне незгоде, геолокација места саобраћајне незгоде (X,Y координате), тежина саобраћајне незгоде, категорија саобраћајне незгоде, као и опис саобраћајне незгоде. Скуп података садржи преко 30.000 записа, што омогућава поузданију анализу и моделовање. Подаци потичу из отворених извора (енгл. open data), односно званичних евиденција о саобраћајним незгодама, и представљају реалне догађаје забележене у пракси. Скуп података је преузет са портала data.gov.rs(https://data.gov.rs/sr/datasets/podatsi-o-saobratshajnim-nezgodama-po-politsijskim-upravama-i-opshtinama/). Скуп је обогаћен метеоролошким подацима прибављеним из јавно доступног Open-Meteo API-ја на основу координата и времена сваке незгоде. Додата обележја су: температура ваздуха на 2 метра висине, количина падавина, брзина ветра на 10 метара висине, облачност у процентима и код временских услова Светске метеоролошке организације. Такође скуп је проширен подацима о путевима који су добављени из базе OpenStreetMap. Обележја овог скупа су: категорија пута, изворни OSM тип пута, ограничење брзине, број саобраћајних трака, једносмерност, тип подлоге , индикатори тунела и моста, име и референца пута.

2.2. Претходни слични подухвати других особа

Предикција тежине исхода саобраћајних незгода представља добро истражено подручје у научној литератури из области интелигентних транспортних система и науке о подацима.

Један од сличних радова јесте студија коју су спровели Alkheder, Taamneh и Taamneh (2017) [1], у којој је над скупом од 5.973 саобраћајне незгоде забележене у Абу Дабију (2008–2013) примењен хибридни приступ K-means кластеризације и вештачке неуронске мреже. Њихов модел је постигао тачност класификације од 81,6% на скупу за обучавање и 74,6% на тест скупу, при чему је кластеризација пре класификације показала побољшање перформанси у односу на саму неуронску мрежу. Сличан методолошки оквир представили су Alikhani, Nedaie и Ahmadvand (2013) [2], који су за класификацију тежине незгода у Ирану комбиновали K-means и self-organizing maps (SOM) са вештачким неуронским мрежама.

У домену фази логике, Meng и сарадници (2009) [3] предложили су Мамданијев фази модел за предикцију учесталости саобраћајних незгода са 41 фази правилом и улазним променљивим попут просечног дневног саобраћаја, ширине коловоза, ограничења брзине и оптерећења пута. Zheng и сарадници [4] су касније развили fuzzy neural network модел (FNNM) који комбинује Мамданијеву фази логику са BP неуронском мрежом, демонстрирајући да хибридни приступи често превазилазе појединачне моделе у тачности и флексибилности.

2.3. Методе

Током припреме података извршена је провера и уклањање дупликата, као и идентификација и уклањање недостајућих вредности из података. Затим смо колону датум конвертовали у одговарајући формат и из ње издвојили нова временска обележја (сат, месец и дан у недељи) која ће нам бити потребна у даљој анализи.

Истражна анализа обухватила је испитивање расподеле обележја, међусобних зависности и просторно-временских образаца у подацима. Коришћени су хистограми, кружни дијаграми, heatmap и stacked-bar дијаграми за визуелну анализу, просторна анализа спроведена је преко геокоординате, такође је приказана и интерактивна мапа незгода.

Код кластеризације података, за откривање образаца у структурисаним подацима примењен је K-means алгоритам. Као улазна обележја коришћена су просторна, временска и метеоролошка обележја: географска ширина и дужина, сат, месец, температура, брзина ветра, облачност и WMO код временских услова. Нормализација података је извршена помоћу StandarScaler-a (Z-score стандардизација), како би сва обележја имала једнак допринос у кластеризацији. Оптимални број кластера одређен је комбиновањем две комплементарне методе: методе „лакта" која анализира опадање инерције у зависности од броја кластера, и Silhouette анализе која мери колико добро су примери груписани у односу на остале кластере. Након експерименталног тестирања различитог броја кластера и комбинација различитих обележја који се користе у кластеризацији, оптималан број кластера је 5 (једногласна одлука обе методе).

Предиктивни модел заснован је на вишеслојној неуронској мрежи (MLP), улазни слој представљају следећа обележја: температура, облачност, сат, месец, географска ширина и дужина, категорија незгоде и кластер. Мрежа се састоји од три скривена слоја са 64, 32 и 16 неурона редом, са активационим функцијама ReLU и Tanh и излазног слоја са 3 неурона и softmax активацијом за класификацију у три класе тежине исхода. Регуларизација је остварена Dropout слојем након првог скривеног слоја. Финална архитектура одабрана је експериментално, након тестирања више комбинација. Једноставније мреже са једним или два скривена слоја давале су слабије резултате, док веће мреже са четири или више слојева нису доносиле значајно побољшање, али су се обучавале спорије и имале већу склоност преприлагођавању. Изабрана архитектура са три скривена слоја (64, 32 и 16 неурона) и комбинацијом активационих функција ReLU и Tanh показала је најбољи однос тачности и стабилности обуке. Скуп је стратификованом поделом 80%/20% подељен на тренинг и тест подскуп, чиме је оригинална расподела класа очувана у оба на тај начин . Као функција губитка коришћена је categorical_crossentropy, а оптимизација је извршена Adam алгоритмом. Пре коначног избора оптимизатора, тестирано је више различитих оптимизатора (Adam, SGD и Adagrad) , при чему је Adam задржан због најбоље комбинације брзине конвергенције и стабилности.

Обрада текстуалних описа незгода спроведена је регуларним изразима (regex), при чему су дефинисано препознавање шаблона кључних делова у тексту. Из колоне опис извучено је 30 бинарних обележја, организованих у пет група: врста учесника, типови маневара (скретање лево/десно, претицање, сустизање, полукружно окретање, унапред/уназад, чеони сударе), околности и локација (раскрсница, кривина, тротоар, путни радови, препрека), тип судара (силазак, превртање, отварање врата, исти/супротни смер), и смер пешака (с лева, с десна, стоји, дуж коловоза). Свака незгода је затим класификована у једну од девет тематских група што олакшава интерпретацију и каснију употребу у фази систему.

Статичка анализа спроведена је над NLP обележјима, али и над осталим обележјима скупа. Коришћене су следеће методе: Crosstab метода за приказ заједничке расподеле обележја и тежине исхода, Chi-square тест независности за процену статистичке значајности повезаности, Крамеров коефицијент V као мера јачине везе између категоричких променљивих, Spearman ρ за процену рангирне корелације код ординалних обележја. Резултати ове анализе чинили су основу за дефинисање фази правила у наредној фази.

Фази систем претвара обележја незгоде у четири улаза на скали од 0 до 10 (рањивост учесника, ризик маневра, контекст пута и време), фазификује их троугаоним функцијама припадности са три терма који се преклапају, примењује базу од девет основних правила (плус допунска у варијантама са временом и путем) Мамданијевог типа и дефазификује излаз методом центроида. Тако добијен непрекидни излаз са птаговима од 0 до 2 се сврстава у једну од три класе, при чему се прагови уче на тренинг скупу максимизујући macro-F1, а мере на издвојеном тест скупу (стратификована подела 70:30).

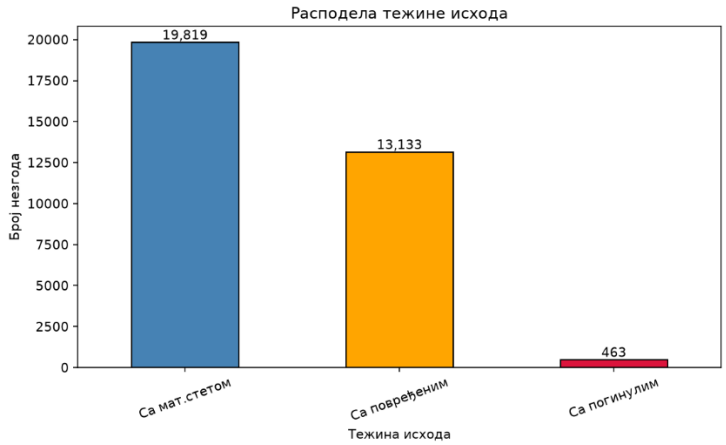
За евалуацију оба развијена модела коришћене су стандардне метрике за вишекласну класификацију: тачност (accuracy)**,** прецизност (precision)**,** одзив (recall)**,** F1(macro) мера и матрица конфузије**.** Због изражене неуравнотежености класа (само 1,4% незгода има смртни исход), као референтна метрика одабрана је F1(macro)**,** која пружа у нашем случају реалнију процену перформанси него обична тачност.

3. Резултати

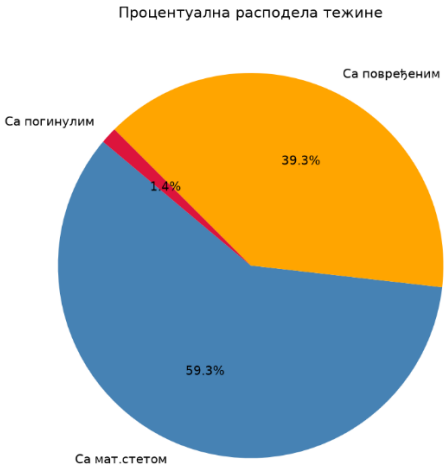
3.1. Приказ резултата

Резултати истражне анализе:

Графикони 1 и 2 приказују расподелу циљне променљиве - тежине исхода саобраћајне незгоде.

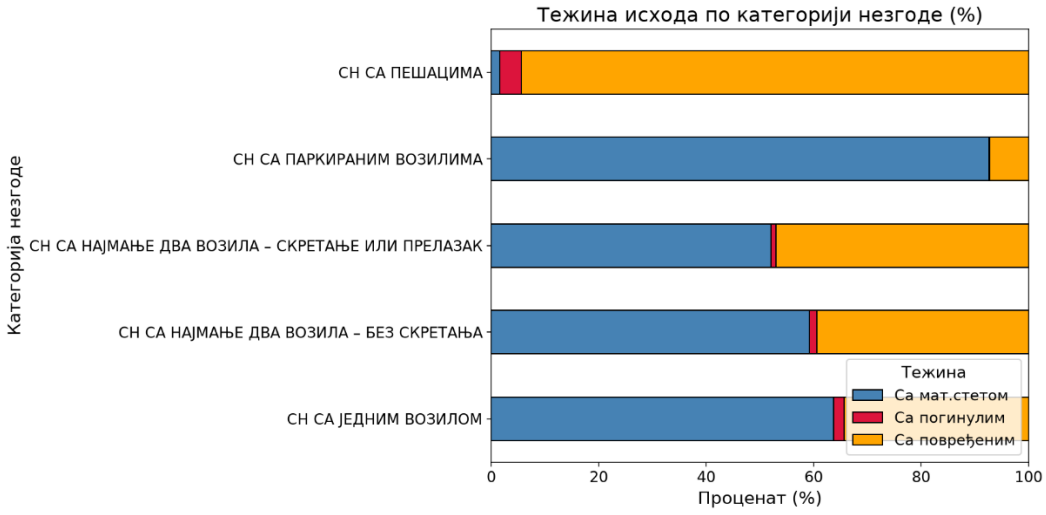


Графикон 1



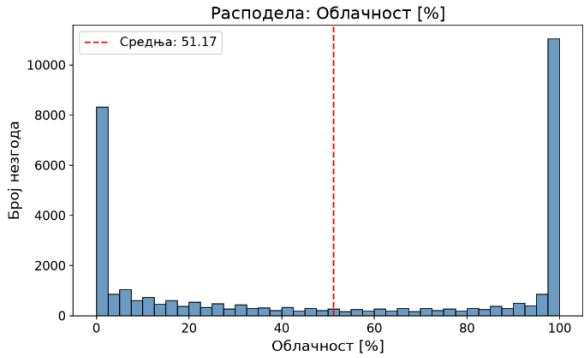
Графикон 2

Графикон 3 приказује процентуалну расподелу тежине исхода унутар сваке категорије саобраћајне незгоде. Видљиве су значајне разлике међу категоријама, као и повезаност категорије и тежине незгоде.

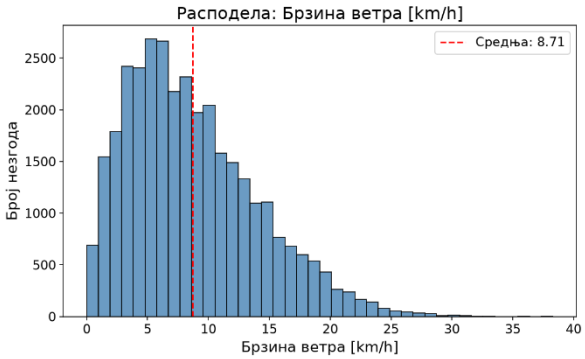


Графикон 3

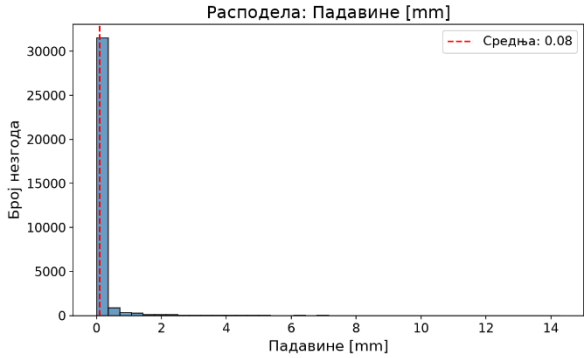
Графикони 4-7 приказују расподеле четири метеоролошка обележја у скупу.



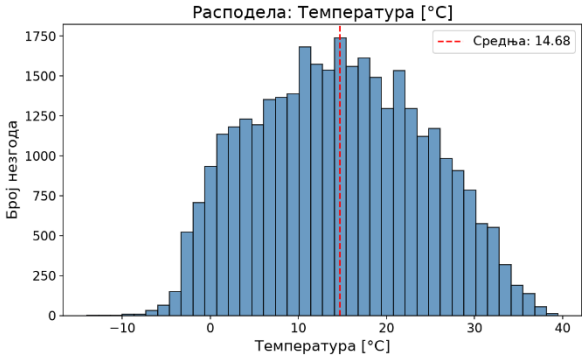
Графикон 4



Графикон 5

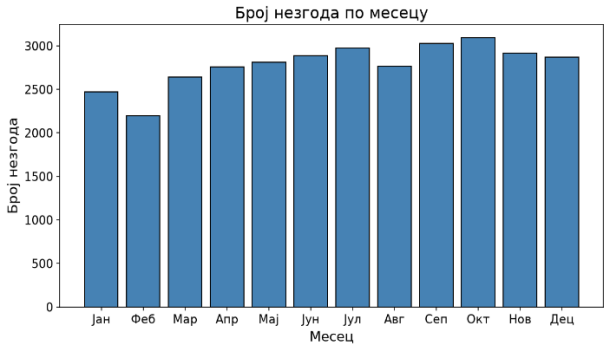


Графикон 6



Графикон 7

Графикони 8 и 9 приказују временску расподелу саобраћајних незгода током 2025. године. Графикон 8 (по месецу) показује приближно равномерну расподелу броја незгода током године, са вредностима у опсегу од око 2.200 до 3.100 незгода месечно. Графикон 9 (по сату у току дана) приказује изражену цикличну расподелу: најмањи број незгода јавља се у раним јутарњим сатима, након чега број нагло расте са почетком радног дана, највећи број незгода се дешава између 12 и 17 часова, да би се потом постепено смањивао до поноћи.

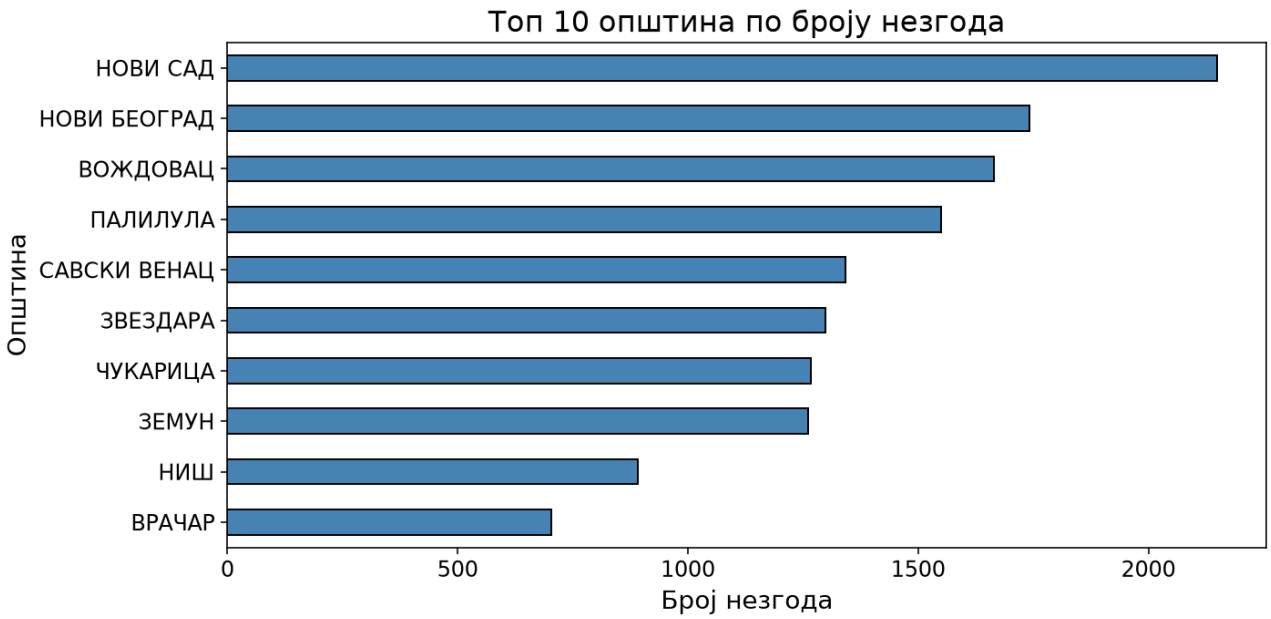


Графикон 8



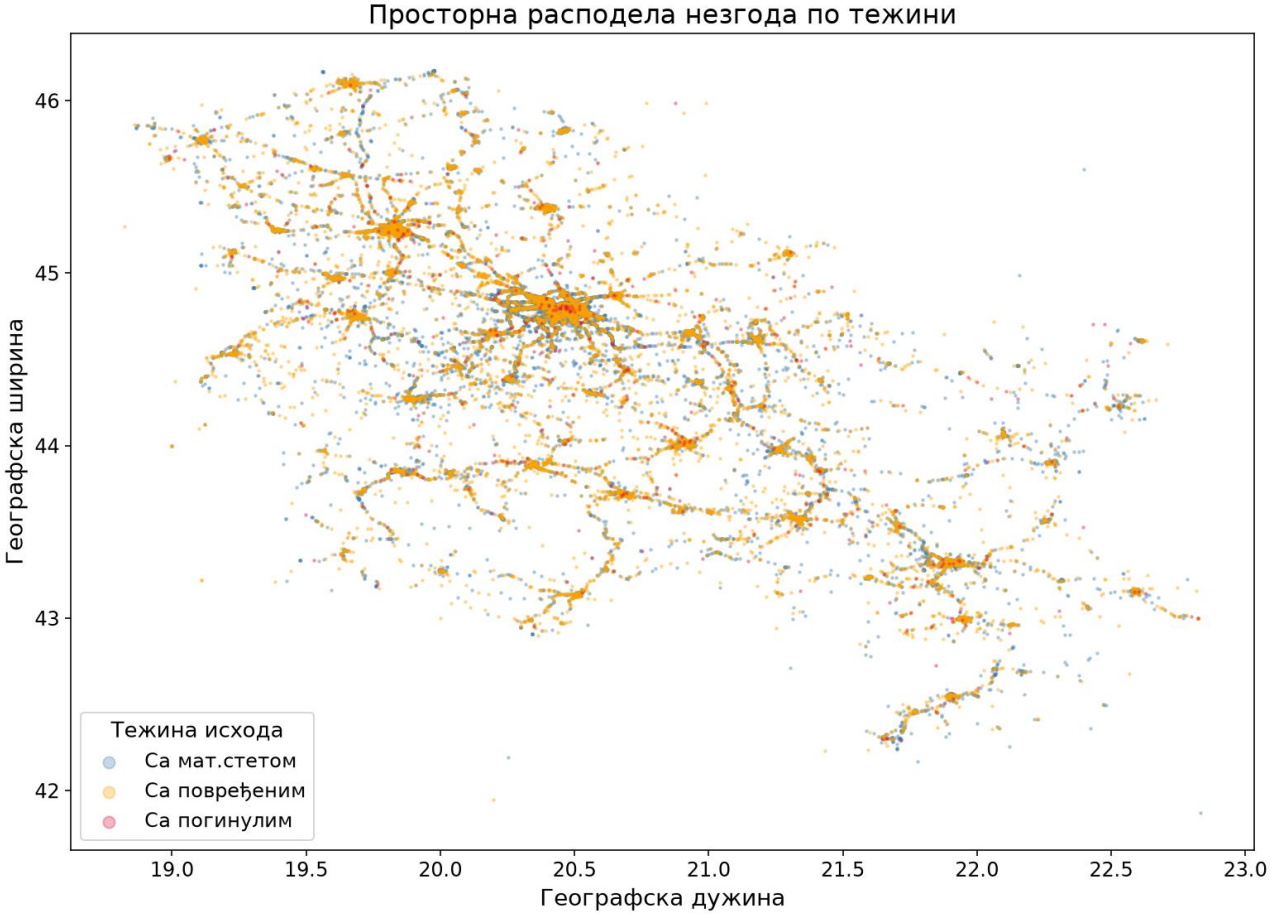
Графикон 9

Графикон 10 приказује десет општина са највећим бројем забележених саобраћајних незгода у 2025. години.



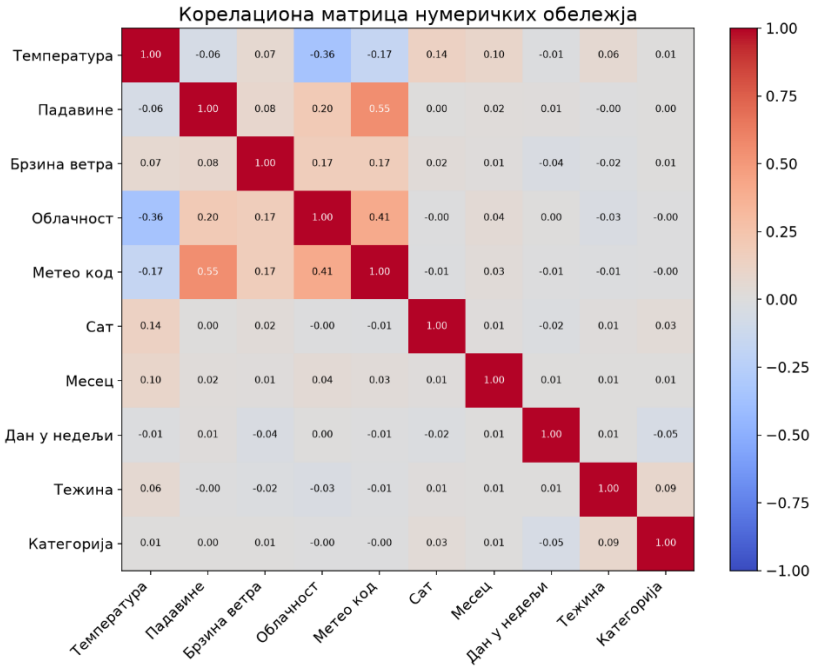
Графикон 10

Графикон 11 приказује просторну расподелу свих забележених саобраћајних незгода на територији Републике Србије у 2025. години, при чему је свака незгода обележена бојом према тежини исхода. Видљиво је изражено концентрисање незгода у централним урбаним зонама, посебно око Београда као и распростирање дуж главних саобраћајница (аутопутева и магистралних путева), које се на графикону уочавају као јасно издвојене линије.



Графикон 11

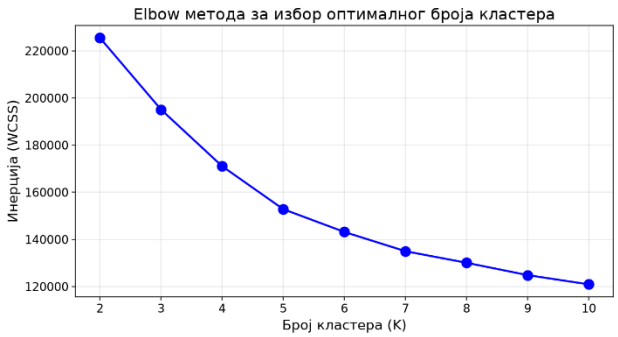
Графикон 11 приказује корелациону матрицу свих нумеричких обележја у скупу. Корелације циљне променљиве (тежине) са свим осталим обележјима су веома слабе и крећу се у распону од –0,03 до 0,09, при чему је највећа корелација забележена са категоријом незгоде (ρ = 0,09).



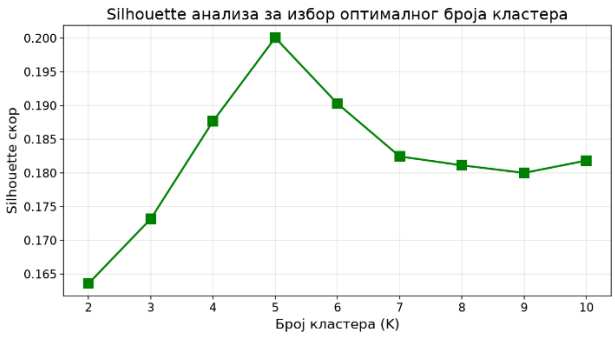
Графикон 12

Резултати одређивања оптималног броја кластера и саме кластеризације:

Графикон 12 су резултати методе „лакта", показује опадање инерције (WCSS) са повећањем броја кластера од 2 до 10, док је графикон 13 метода „силете". На основу ових резултата изабран оптимални број кластер је 5.



Графикон 13



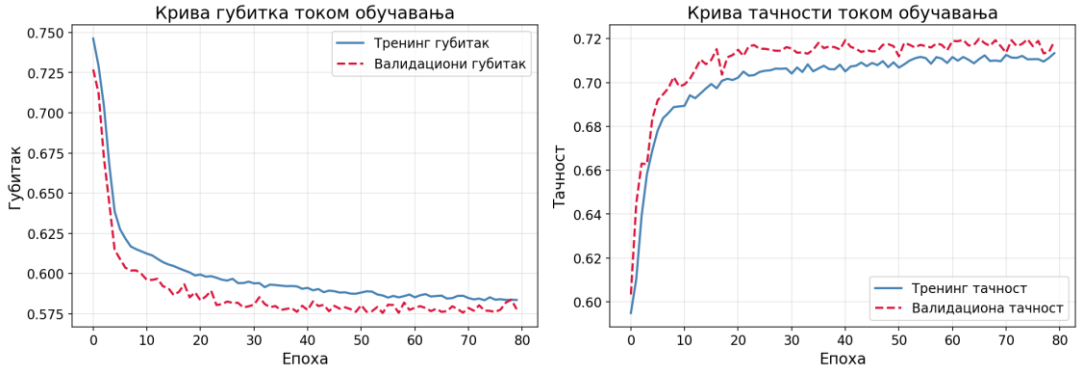
Графикон 14

Број саобраћајних незгода по кластерима:

Кластер 0	4219
Кластер 1	7412
Кластер 2	10300
Кластер 3	6640
Кластер 4	4844

Резултати имплентиране неуронске мреже:

Графикон 15 приказује криве губитка и тачности неуронске мреже током 80 епоха обучавања.



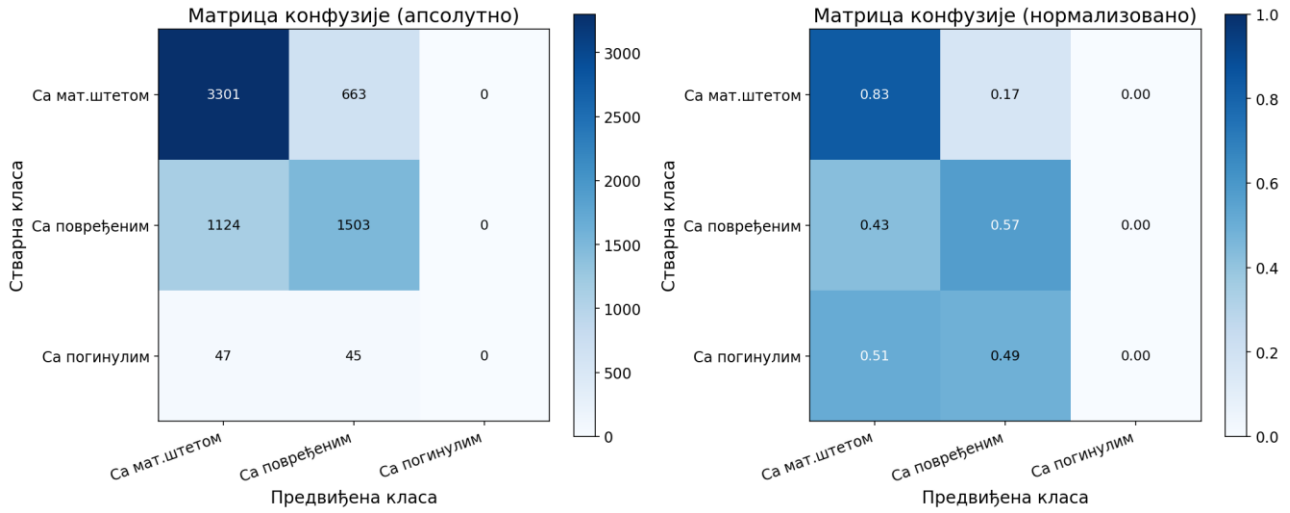
Графикон 15

Резултати примењених метрика:

F1 (macro) – референтна метрика	0.46
Тачност (accuracy)	0.71
Прецизност (precision)	0.47
Одзив (recall)	0.46

Детаљан извештај о класификацији:

class	precision	recall	f1-score	support
Са мат.штетом	0.73	0.83	0.78	3964
Са повређеним	0.68	0.57	0.60	2627
Са погинулим	0.00	0.00	0.00	92

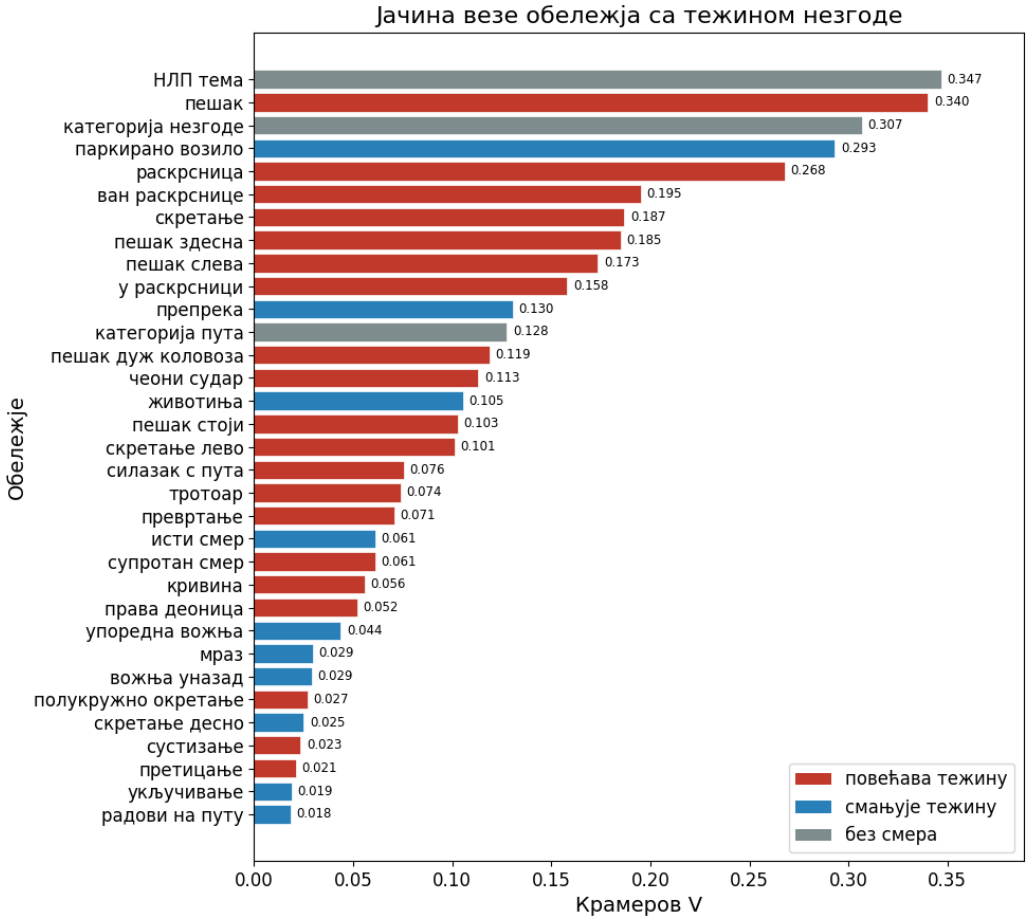


Графикон 16

Такође сам анализирала погрешне процене, укупно погрешних процена је 1924 / 6683, док је проценат погрешних 28.79%.

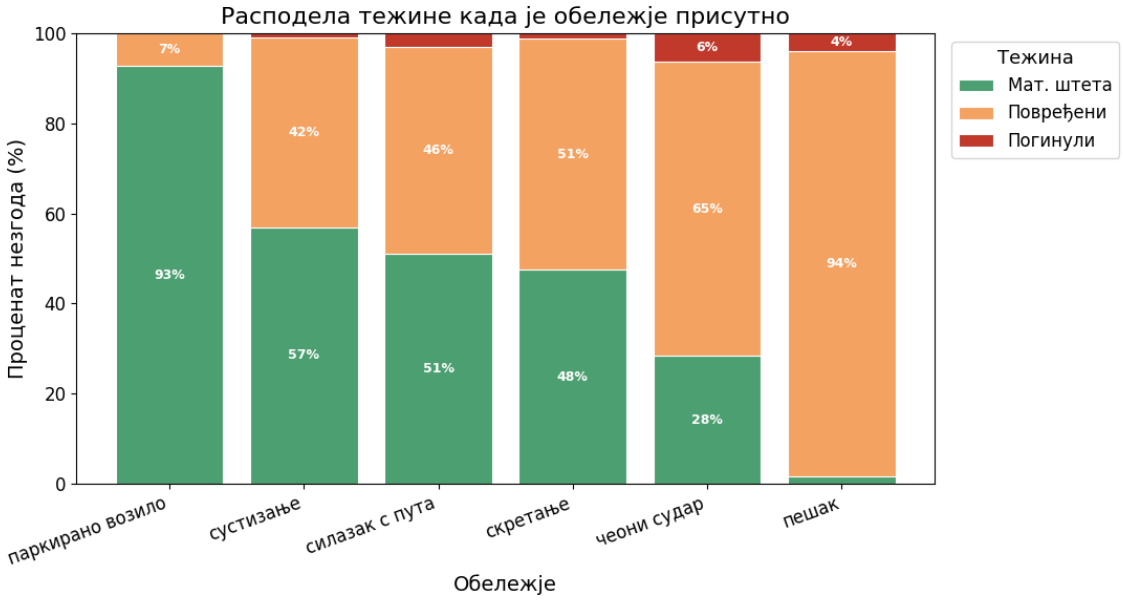
Резултати фази система:

Графикон 17 приказује јачину и смер везе сваког обележја са тежином исхода, изражену Крамеровим коефицијентом V (вредности од 0 до 1, где веће значи јачу везу). Ово рангирање послужило је као основа за бодовање фази улаза.



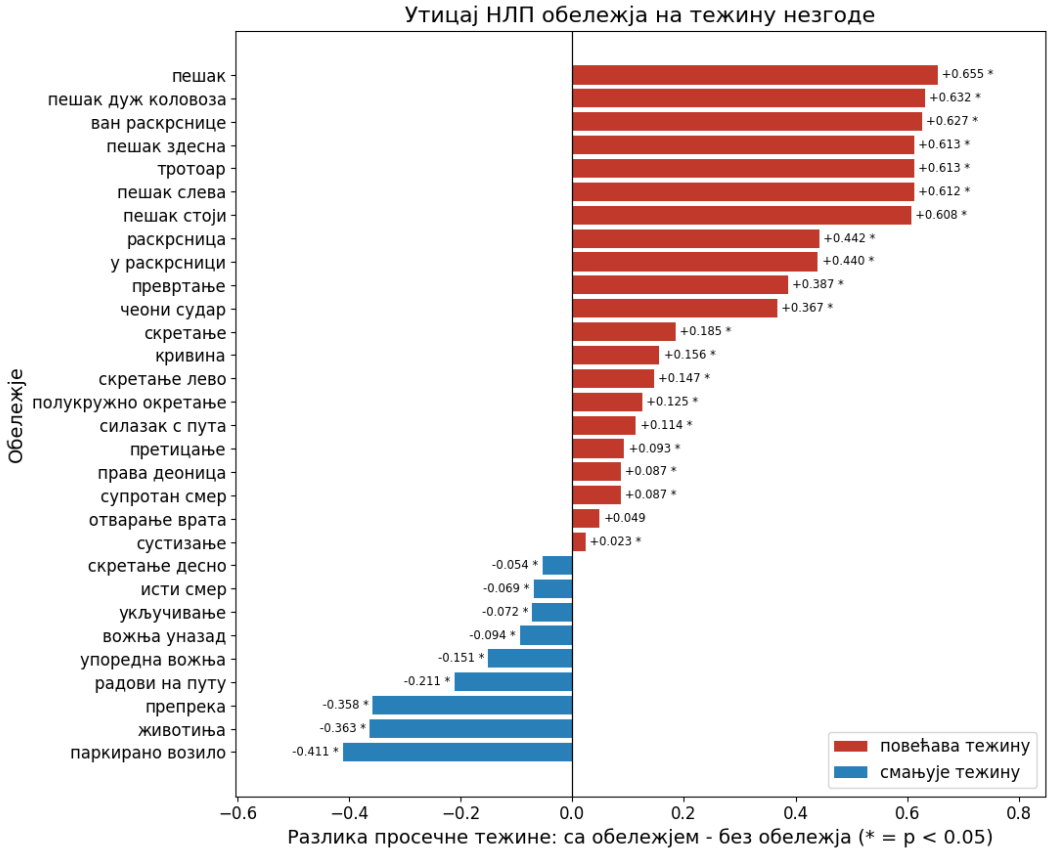
Графикон 17

Графикон 18 приказује расподелу тежине исхода за кључна обележја када су присутна, изражену као удео три класе (материјална штета, повређени, погинули). Разлике међу обележјима су драстичне: код незгода са пешаком чак око 98% има повређене или погинуле, док је код паркираног возила преко 90% само материјална штета.



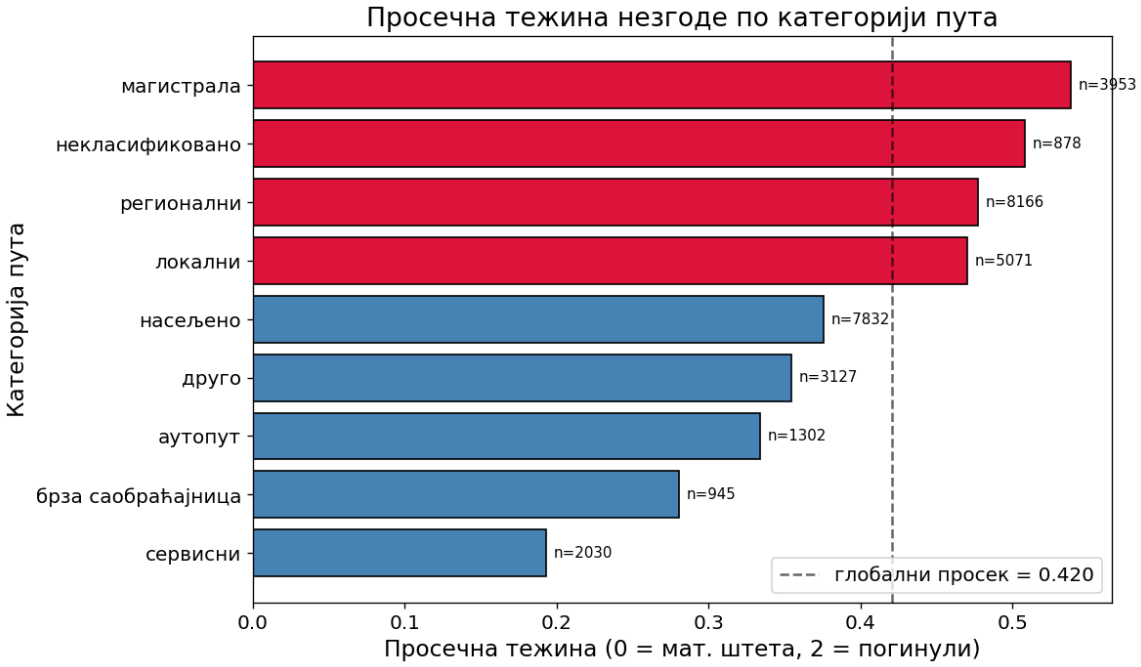
Графикон 18

Графикон 19 приказује разлику у просечној тежини незгоде када је обележје присутно у односу на када га нема, за сва НЛП обележја.



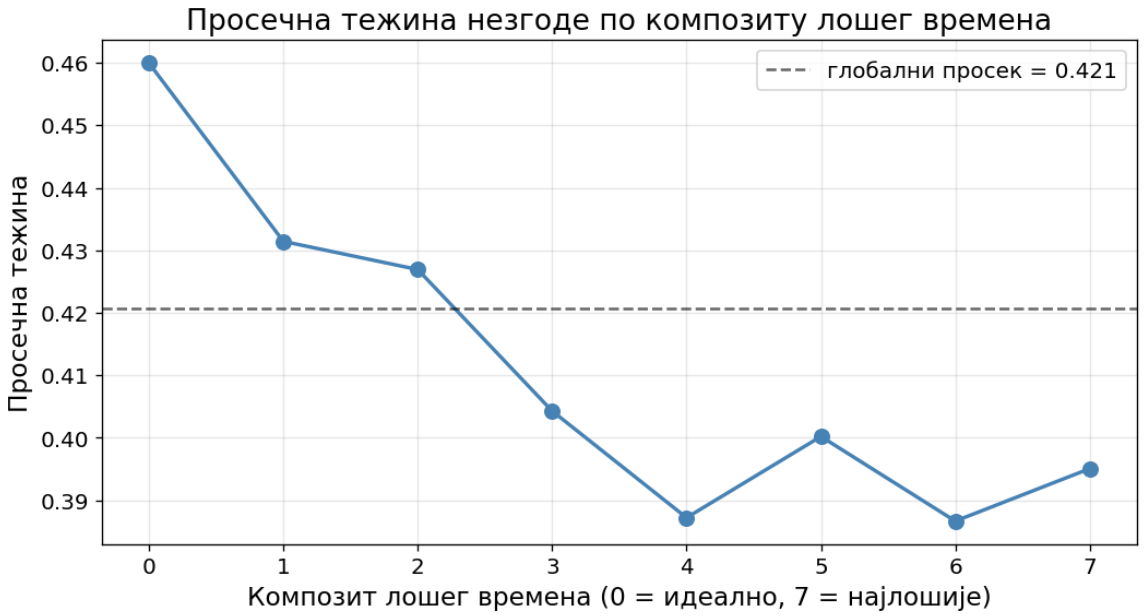
Графикон 19

Графикон 20 приказује просечну тежину незгоде по категорији пута, сортирану од најризичније ка најмање ризичној, у односу на глобални просек.



Графикон 20

Графикон 21 приказује просечну тежину незгоде по композиту лошег времена (на скали од 0 - идеално, до 7 - најлошије), у односу на глобални просек. Уместо да тежина расте са лошијим временом, она је највиша баш по ведром времену (око 0,46) и благо опада ка лошијем, остајући све време близу просека.

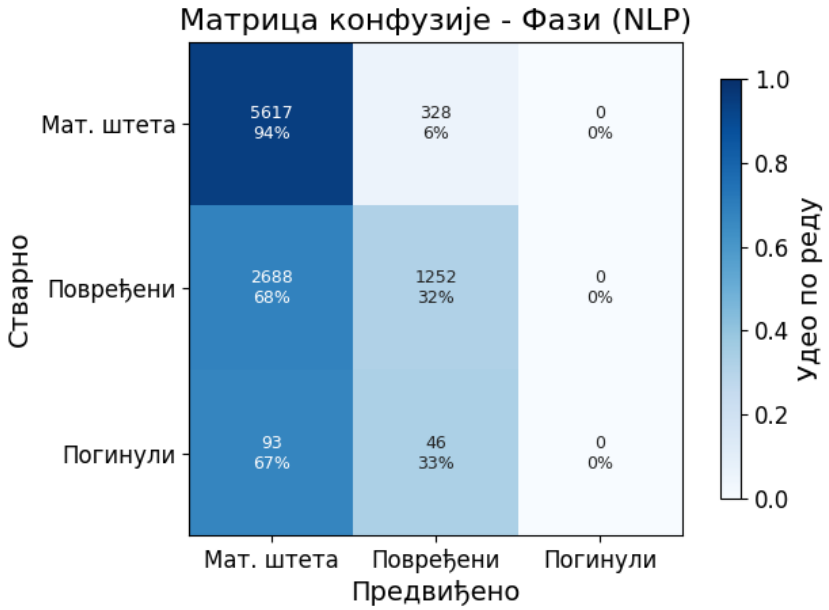


Графикон 21

Резултати примењених метрика:

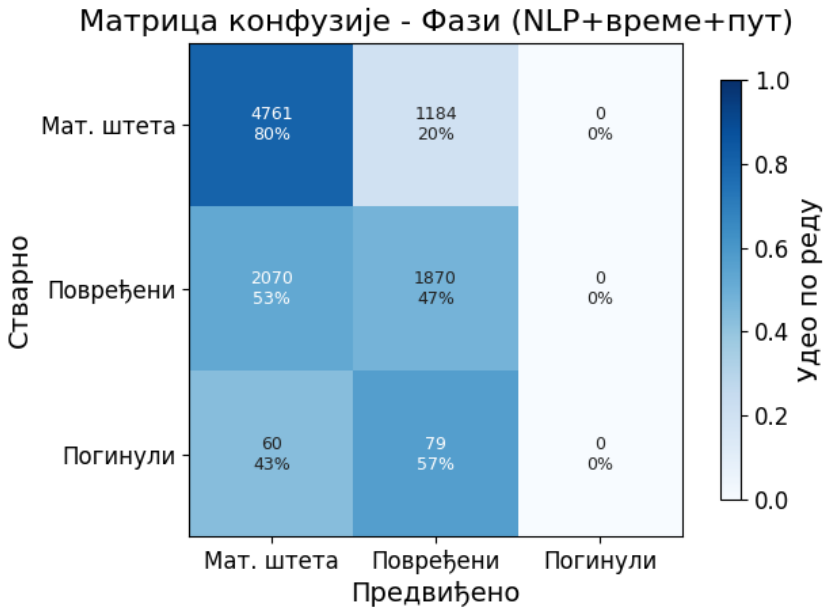
Метрика	**Већинска основа**	**НЛП**	**НЛП+време**	**НЛП+пут**	**пун модел**
Тачност	0,5931	0,6853	0,6853	0,6754	0,6615
F1 (macro)	0,2482	0,411	0,411	0,4288	0,4235
Одзив (macro)	0,3333	0,4209	0,4209	0,4306	0,4252
F1 мат. штета	0,7446	0,7832	0,7832	0,7583	0,7418
F1 повређени	0	0,4499	0,4499	0,5282	0,5288
F1 погинули	0	0	0	0	0

Графикон 22 приказује матрицу конфузије фази система за варијанту само НЛП



Графикон 22

Графикон 23 приказује матрицу конфузије пуног модела (НЛП+време+пут), који користи сва четири улаза.



Графикон 23

3.2. Тумачење резултата

Расподела тежине исхода саобраћајне незгоде која је приказана на Графикону 1 и 2 једна је од најважнијих делова истражне алализе, на основу ње закључујемо да је скуп података значајно неуравнотежен, веома доминира класа класа „Са мат. штетом" са скоро 60%, док је изразито мали број незгода са смртним исходом, само 1,4%. Управо због тога изабрана је F1(macro) мера , која уравнотежено посматра прецизност и одзив и осетљивија је на грешке у предикцији мање заступљених класа, на тај начин желели смо да спречимо да модели „науче" да предвиђају доминантну класу занемарујући ретке класе, јесте да тиме постижу добру тачност, али то није стварно корисно у пракси.

Графикон 3 открива један од најзначајнијих образаца у читавом скупу података – запажамо да незгоде са пешацима скоро увек резултују повредама (94%), незгоде са паркираним возилима практично само доносе материјалну штету (92%), док незгоде са једним возилом имају највећи релативни удео смртних исхода, што може да се повеже са губитком контроле возача, великом брзином или излетањем са пута. На основу ових резултата уочавамо јасну повезаност категорије несреће са циљним обележјем, баш због овога категорија се користи у кластеризацији јер би требало да помогне у проналажењу образаца, а такође би и неуронска мрежа требало да доста научи од ње.

Бимодална расподела облачности (Графикон 4) указује на то да се већина незгода одиграва или при потпуно ведром или при потпуно облачном времену, са веома мало случајева у неким међустањима, на основу овога закључујемо да би ово обележје било доста корисно за кластеризацију и предикцију неуронске мреже.

Расподела падавина (Графикон 6) приказује неочекиван резултат: преко 75% незгода десило се у потпуно сувом времену, са просечном вредношћу од свега 0,08 mm. Овај резултат супротставља се уверењу да су падавине главни узрок саобраћајних незгода. Ово обележје је због овога слабо информативно за наше моделе.

Расподеле температуре (Графикон 7) и брзине ветра (Графикон 5) приказују очекиване обрасце: температура прати приближно нормалну расподелу карактеристичну за климу Србије, са средњом вредношћу од 14,68°C, док је брзина ветра говори о томе да је ветар углавном благ. Иако на основу овога не можемо да закључимо да су ова обележја претерано корисна sa кластеризацију и предиктивни модел, укључујемо их ради разноврсности контекста у којем се незгоде дешавају.

Расподела по месецима (Графикон 8) показује сезонски образац - у топлијој половини године (од маја до октобра) бележи се већи број незгода у односу на зимски период. Знатно изражен образац видљив је у расподели по сату у току дана (Графикон 9): број незгода нагло расте са почетком радног дана од 6 до 8 часова, достиже свој максимум током поподневних часова (12-17h) и постепено опада до поноћи, при чему је најмањи број забележен око 4 часа ујутру. Ово и јесте очекивано јер се уствари највећи број незгода дешава тада када има највише саобраћаја. Можемо их користити у кластеризацији и за неуронску мрежу, пружиће нам додатни временски контекст за предикцију и проналажење образаца.

Са Графикона 10 закључујемо да Београд апсолутно доминира по броју саобраћајних незгода, чак 8 од 10 општина са највећим бројем несрећа су општине Београда, ово је очекиван резултат с обзиром на густину саобраћаја у Београду. Иако је Ниш трећи град по величини има мањи број незгода од већине београдских општина, претпостављамо баш због разлике у густини саобраћаја.

Графикон 11 пружа јасну потврду неколико кључних запажања. Прво, незгоде су концентрисане око главних саобраћајница и урбаних центара - јасно се уочавају линеарни обрасци дуж аутопутева и магистрала, видимо колико је градска подручја знатно разликују од руралних по броју несрећа. Иако географске координате јасно показују где се незгоде дешавају, оне не дају корисне информације какве су по тежини. Другим речима, локација је сама по себи слаб предиктор тежине исхода, видимо да се у Београду дешавају и лаке и тешке незгоде, исто као и у другим градовима. Због тога је од суштинског значаја било обогаћивање модела другим обележјима (категорија незгоде, метеоролошки услови, време дана) која носе информацију о околностима под којима је дошло до незгоде, а самим тим и о њеној могућој тежини. Такође када се овом обележју придодају подаци о путевима, оно постаје значајно за фази системе.

Графикон 12, односно матрица корелација показује да су линеарне везе између тежине исхода незгоде и било ког појединачног обележја веома слабе, али ово не значи да обележја нису корисна и информативна, већ да су њихове везе вероватно нелинеарне, то је управо разлог због којег је одабран приступ заснован на неуронској мрежи, која путем својих скривених слојева и нелинеарних активационих функција може да научи сложене обрасце које матрица корелација не може да детектује.

Графикони 13 и 14 заједнички указују на K = 5 као оптималан број кластера**.** Elbow метода показује карактеристичан „лакат" у опсегу од K = 4 до K = 5, где даље повећање броја кластера резултује све мањим смањењем инерције, што сугерише да се већи број група не би довољно исплатио у односу на додатну сложеност. Silhouette анализа још јасније фаворизује K = 5, са јединственим максимумом од 0,20, након чега вредност постепено опада. Вредност максимума од 0,20 указује на умерену, али не и изражену одвојеност кластера, иако ово није најпожељнији исход, експериментално смо покушали и друге комбинације улаза, као и броја кластера, али све опције су дали знатно гори исход од овог изабраног.

Анализа просечних вредности обележја по кластерима омогућила је њихову семантичку интерпретацију: Кластер 0 обухвата незгоде у изразито лошим временским условима, Кластер 1 приказује делимично облачне и суве услове, Кластер 2 представља незгоде при ведром времену, Кластер 3 одговара претежно облачним али сувим условима, док Кластер 4 одступа од осталих по просторној димензији, његове просечне координате одговарају јужном делу Србије, чиме се он издваја као једини кластер са израженом географском специфичношћу. Кластер 2 има већи број незгода у односу на остале, али тај дисбаланс није проблем јер није превелик, донекле је и очекиван.

Графикон 15 пружа изузетно важан закључак о понашању неуронске мреже током процеса обучавања и приказује неколико значајних својстава модела. Обе криве (тренинг и валидациона) показују глатку и стабилну конвергенцију, без знакова нестабилности или дивергенције. Можда и најзначајније запажање је то да је валидациона крива губитка током читавог процеса обучавања нижа од тренинг криве, односно валидациона тачност је виша од тренинг тачности. Овакав образац је јасан показатељ одсуства преприлагођавања (overfitting-a). Овакво понашање је директна последица успешне регуларизације кроз Dropout слој са вероватноћом од 0,3, током обучавања, насумичних 30% неурона је искључено, што мрежу чини „слабијом" у том тренутку и доводи до нешто веће тренинг грешке. Овакви резултати потврђује да су методолошки избори - архитектура мреже (64–32–16 неурона), јачина регуларизације (dropout = 0,3) и број епоха обучавања (80) добро подешени за задати проблем и величину скупа података.

Референтна метрика F1 (macro) износи 0,46. Иако вредност на први поглед делује ниско, она реално приказује тежину задатка предвиђања на екстремно неуравнотеженом скупу. Детаљну слику предвиђаља по класама пружа матрица конфузије. Класа „Са мат. штетом" препозната је са одзивом од 83% (3.301 од 3.964 примера), што показује да модел поуздано идентификује најчешћи исход, што је и очекивано јер је ово изразито доминантна класа. Класа „Са повређеним" препозната је са одзивом од 57% (1.503 од 2.627 примера), при чему је најчешћа грешка управо мешање са „Са мат. штетом" - што је и логично, јер ове две класе у пракси често имају слично контекстуално окружење. Међутим, класа „Са погинулим" има одзив од 0% - ниједан од 92 примера ове класе модел није исправно класификовао, већ их је све распоредио између две доминантне класе. Управо овај потпуни неуспех на најмањој класи је и кључни разлог зашто је F1 (macro) релативно ниска, јер нулта вредност F1 на једној класи директно повлачи укупни просек надоле. Овакав резултат на класи „Са погинулим" последица је њеног ниског удела у скупу (1,4%). Експерименталим тестирањем различите архитектуре неуронске

мреже и других опција као сто је class_weight, покушали смо да минимизујемо грешку, али се ово коначно решење показало као најбоље од свих испробаних, постигло је највишу референтну метрику F1 (macro) уз најуравнотеженији успешност међу испробаним варијантама.

Експериментална провера показала је да кластери као додатно улазно обележје не доносе значајно побољшање модела. Разлог је тај што кластери не пружају мрежи нове информације нити нове обрасце, имплементирана мрежа кроз своје скривене слојеве сама може да научи исте односе и обрасце које кластеризација покушава да изрази. Такође и то смо покушали да решимо, али када додамо потпуно другачија обележја, или нека која нису толико информативна током кластеризације ради откривања другачијих образаца, подела на кластере постаје бесмислена и тривијална што опет није добро решење.

Графикон 17 (Крамеров V) мери јачину везе сваког обележја са тежином: пешак има најјачу позитивну (V око 0,34), а паркирано возило најизразитију негативну (V око 0,29). Графикон 18 то преводи у конкретне уделе - код незгода са пешаком чак око 98% има повређене или погинуле, док је код паркираног возила преко 90% само материјална штета - а графикон 19 исти образац показује кроз разлику просечне тежине са и без обележја. Зато рањивост узима вредност 9 за пешака, а свега 0,5 до 1 за паркирано возило и животињу, на исти начин рангиран је и ризик маневра. Пошто баш ова обележја носе највећи значај, она и у резултатима дају највећи допринос тачности.

Графикон 20 оправдава контекст пута као четврти улаз: од свих путних обележја категорија пута има најјачу везу са тежином, при чему је магистрала најризичнија (просечна тежина око 0,54), а аутопут и сервисни путеви најмање, зато варијанта са путем у резултатима даје благо побољшање. Насупрот томе, графикон 21 показује да време слабо утиче на тежину - она је највиша по ведром времену и тек благо опада ка лошијем. То унапред наговештава оно што се види у резултатима - додавање времена не доноси значајно побољшање.

Прелазећи на саме резултате, све четири варијанте фази система убедљиво надмашују већинску основу: macro-F1 расте са 0,25 на 0,41, а код најбоље варијанте на 0,43, уз пораст одзива са 0,33 на 0,43 и тачности са 0,59 на 0,69. Пошто већинска основа увек предвиђа материјалну штету и има F1 = 0 за повређене и погинуле, овај скок показује да систем заиста учи корисну структуру, а не да само погађа најчешћу класу. Ипак ови резултати као и код модела неуронске мреже показују да модел поуздано класификује најчешћу класу („Са мат.штетом"), солидно препознаје повређене, док најређу класу („Са погинулим") готово никако не препознаје.

Поређење варијанти потврђује резултате са графикона. Варијанта само НЛП постиже тачност 0,69 и macro-F1 0,41. Додавање времена не мења ништа - варијанта НЛП+време даје идентичне бројеве, тачно како наговештава слаб утицај времена. Контекст пута умерено помаже: НЛП+пут постиже највиши macro-F1 (0,43), пре свега зато што подиже одзив за класу повређених са 0,32 на 0,45, а F1 за повређене са 0,45 на 0,53. Пун модел има нешто нижи резултат (0,42) јер време и овде уноси шум. Највећи део утицаја, дакле, носе обележја из текстуалног описа, што је у складу са важношћу обележја са претходних графикона.

Што се тиче матрице конфузије у варијанти само НЛП (графикон 22) ред материјалне штете има изражену дијагоналу (око 94% тачно), док се редови повређених и погинулих расипају улево, ка лакшим класама. Пун модел (графикон 23) има нешто бољи одзив за повређене, али на класу погинули и даље не утиче. У оба случаја колона погинули остаје празна - ниједан стварни смртни исход није предвиђен као такав, што и даје F1 = 0 за ту класу.

Упоредном анализом два развијена модела утврђено је да оба приступа постижу веома сличне резултате на истом задатку (неуронска мрежа са F1 (macro) од 0,46 и фази систем са вредношћу 0,43) при чему оба модела имају иста ограничења: веома солидну предикцију доминантних класа и отежано препознавање најређе класе. Овакво подударање резултата кроз методолошки потпуно различите приступе указује на то да постигнути ниво успешности не зависи највише од методологе и приступа, већ од структуре и природе самог скупа података, пре свега од изразите неуравнотежености класа и слабих линеарних веза између обележја и циљне променљиве.

4. Закључак

4.1. Анализа испуњења циља

Главни циљ пројекта односно развој модела за што поузданију предикцију тежине исхода саобраћајне незгоде и упоредна анализа два методолошки различита приступа није у потпуности остварен. Оба предвиђена модела су успешно развијена, обучена и евалуирана на стварном скупу података о саобраћајним незгодама забележеним у Републици Србији 2025. године.

Кроз спроведену истражну анализу идентификовани су кључни просторно-временски и метеоролошки обрасци у подацима, као и утицај појединих обележја на циљну променљиву што је била одлична основа за даљи рад. Кластеризација није идеална, али је успешно издвојила групе незгода са појединим сличним карактеристикама, а добијени кластери су интегрисани у неуронску мрежу као додатно улазно обележје како би побољшали предикцију самог модела, али је побољшање скоро неприметно. Имплементирана вишеслојна неуронска мрежа постигла је F1 од 0,46 и тачност од 71,88%, што представља значајно побољшање у односу на тривијално предвиђање доминантне класе (тачност приближно 59%).

Паралелно са тим, обрадом природног језика издвојен је сет релевантних бинарних обележја из текстуалних описа, чија је повезаност са тежином исхода квантификована применом Chi-square теста независности, Крамеровог коефицијента V и Spearman ρ коефицијента. На основу ових резултата, успешно је дефинисан и имплементиран Мамданијев фази систем у више варијанти, при чему је најбоља конфигурација постигла F1 (macro) од 0,43, што је резултат сасвим упоредив са резултатом неуронске мреже.

Упоређивањем перформанси оба развијена модела достигнут је и најшири циљ пројекта - закључак о томе како се ова два методолошки различита приступа понашају на истом задатку. Оба приступа показала су веома сличне резултате и слична ограничења, без оштре доминације једног над другим. Заједнички проблем оба модела јесте отежано препознавање најређе класе - незгода са смртним исходом, која у скупу чини свега 1,4% случајева. Иако је ово ограничење препознато и делимично третирано избором F1 (macro) мере као референтне метрике, која онемогућава да модел занемари ретку класу без последица по укупну евалуацију, потпуна детекција ове класе остаје изазов који захтева напредније технике за рад са изражено неуравнотеженим скуповима података. Овај закључак с једне стране умањује квалитет обе предикције, али са друге представља значајан и реалан резултат пројекта који осликава ограничења наметнута самом природом података.

4.2. Анализа остварења очекиваних резултата

Очекивање да ће примењене методе омогућити што поузданију предикцију тежине исхода остварено је делимично, и то у границама које намеће сам скуп података. Оба модела убедљиво надмашују тривијално предвиђање доминантне класе - неуронска мрежа постиже тачност од 71,88% и F1 (macro) 0,46, а фази систем тачност до 0,69 и F1 (macro) 0,43, чиме се потврђује да модели заиста уче корисну структуру. Ипак, поуздана предикција показала се ограниченом због изразите неуравнотежености класа, зато ниједан од два модела не успева да поуздано препозна најређу класу (незгоде са смртним исходом).

Што се тиче резултата откривања значајних образаца у подацима, у великој мери су очекивања испуњена. Истражна анализа открила је јасне просторно-временске обрасце (велики број

незгода у урбаним језгрима и дуж главних саобраћајница, поподневни и сезонски максимуми), али и неколико неочекиваних резултата, пре свега да падавине и лоше време нису доминантан фактор тежине, чиме је нарушена уобичајена претпоставка.

Допринос кластеризације остварен је само делимично. Кластеризација јесте, како се и очекивало, издвојила групе незгода са сличним просторним, временским и метеоролошким карактеристикама, при чему су добијени кластери били семантички смислени. Међутим, очекивање да ће ти кластери пружити неуронској мрежи користан додатни контекст и тиме побољшати предикцију није се потврдило, њихово укључивање као улазног обележја донело је тек занемарљиво побољшање.

Очекивање везано за обраду природног језика у потпуности је остварено. Из текстуалних описа незгода успешно је издвојен сет обележја која у структурираном скупу нису била директно доступна - врста учесника, тип судара, маневар и контекст у којем се незгода десила.

У складу с тим, остварено је и очекивање да ће статистичка анализа утврдити која су од издвојених обележја најјаче повезана са тежином исхода. Применом Chi-square теста, Крамеровог коефицијента V и Spearman ρ јасно је рангиран утицај обележја, а ово рангирање је, како је и планирано, директно послужило као основа за дефинисање фази правила и бодовање улаза Мамданијевог система.

Што се тиче самих предикција, очекивани ниво успешности био је постигнут само делимично. Очекивало се да ће модели комбиновањем метеоролошких, временских и просторних обележја постићи нешто виши F1 (macro), посебно на класи „Са погинулим". У стварности, неуронска мрежа постигла је F1 (macro) од 0,46, док је фази систем остварио F1 (macro) од 0,43, главни узрок оваквог одступања је изразита неуравнотеженост класа.

На крају су остварени и резултати упоређивањем два методолошки различита приступа и изведен је јасан закључак о њиховој ефикасности и доприносу. Оба приступа показала су веома сличне перформансе и иста ограничења, без доминације једног над другим, што је указало на то да постигнути ниво успешности више зависи од структуре и природе самог скупа података него од избора методологије.

4.3. Могућности за примену резултата у пракси

Резултати овог истраживања могу се применити у више практичних домена повезаних са безбедношћу саобраћаја, односно на планирање мера безбедности саобраћаја и инфраструктурне интервенције. Спроведена анализа је показала да присуство пешака представља најјачи појединачни предиктор тежине исхода саобраћајне незгоде. Одмах за њима, по утицају издвајају се незгоде везане за раскрснице. На основу добијених резултата препоручује се приоритизација заштите пешака, што обухвата изградњу безбедних и осветљених пешачких прелаза, увођење семафора, постављање успоривача саобраћаја и физичко раздвајање пешачких и саобраћајних токова. Поред тога, идентификован је и значајан утицај инфраструктуре раскрсница, што сугерише потребу за њиховим систематичним редизајном. Просторно-временска анализа и кластеризација пружају додатну вредност тиме што омогућавају идентификацију високоризичних деоница и временских интервала - поподневних сати, топлије половине године, урбаних језгара и главних саобраћајница. Овакви закључци у пракси могу да послуже као основа за циљано распоређивање саобраћајне полиције, оптимално постављање саобраћајне сигнализације и надзорних камера.

4.4. Идеје за побољшање и даљу разраду

Иако су оба модела успешно развијена и евалуирана, постоји значајан простор за побољшање, пре свега у решавању кључног проблема односно поузданог препознавања најређе класе (незгоде са смртним исходом). Током израде већ смо испробали низ приступа у том правцу: код неуронске мреже тестирали смо различите архитектуре (од једног до четири и више скривених слојева), више оптимизатора (Adam, SGD, Adagrad), као и технику тежинског балансирања класа (class_weight), код кластеризације смо пробали различите комбинације улазних обележја и различит број кластера, а код фази система развили смо више варијанти улаза и подешавали прагове максимизацијом macro-F1 мере. Ови покушаји довели су до изабраних, најбољих имплеметација, али нису успели да реше суштински проблем неуравнотежености. Али, наравно да постоји још унапређења која бисмо могли да испробамо. Прва група унапређења односи се на напредније технике за рад са изразито неуравнотеженим скуповима података. Уместо простог тежинског балансирања, могле би се применити технике ресемпловања попут хибридних метода (комбинација over-sampling-a и under-sampling-a), као и заменска функција губитка прилагођена ретким класама (нпр. focal loss уместо categorical crossentropy).

Друга група унапређења тиче се обогаћивања самог скупа података, анализа је показала да постојећа обележја немају довољно информација да раздвоје тешке повреде од смртних исхода.

Трећа група односи се на сложеније моделе. Поред коришћене вишеслојне неуронске мреже, могли би се испробати методи попут Random Forest-a и градијентног бустинга (XGBoost), који се у литератури често показују као изузетно успешни управо за предикцију тежине незгода.

5. Литература

[1] Alkheder S., Taamneh M., Taamneh S. (2017). *Severity Prediction of Traffic Accident Using an Artificial Neural Network*. Journal of Forecasting, 36(1), 100–108.

[2] Alikhani M., Nedaie A., Ahmadvand A. (2013). *Presentation of clustering-classification heuristic method for improvement accuracy in classification of severity of road accidents in Iran*. Safety Science, 60, 142–150.

[3] Meng Q., et al. (2009). *Mamdani fuzzy inference system for road accident frequency prediction*.

[4] Zheng L., et al. *An approach to predict road accident frequencies: Application of fuzzy neural network*. Transportation Research Board (TRB).